


Relatório 29 - Trabalho Final do Bootcamp

Felipe Fonseca

1. Introdução

Nesse projeto, eu decidi criar um modelo de machine learning para prever o valor de mercado de jogadores de futebol e também o valor das transferências entre clubes. A ideia era entender como diferentes fatores impactam no preço de um jogador e criar um intervalo de confiança para as negociações. Para isso, eu utilizei uma base de dados bem completa com informações de jogadores, clubes, aparições em jogos e histórico de transferências. O objetivo principal foi dividir o problema em duas etapas: primeiro, prever o valor de mercado justo do jogador usando suas características e desempenho; e depois, usar essa previsão junto com o histórico de gastos dos clubes para estimar a taxa de transferência real.


2. Desenvolvimento




2.1 Análise Exploratória dos Dados

A primeira coisa que eu fiz foi uma análise exploratória dos dados contidos nos diferentes datasets para entender a estrutura e os possíveis problemas que eu teria antes de iniciar qualquer processamento. A ideia era só dar uma olhada no que eu tinha e decidir o que precisa ser tratado.

Comecei analisando o dataset de Clubes e Jogadores. Para os clubes, eu verifiquei rapidamente a quantidade de equipes únicas e a presença de dados faltantes nas informações de ligas domésticas. Já para os jogadores, eu achei importante olhar as distribuições de posições no campo, nacionalidades e se havia algum valor inesperado no pé dominante. Notei também que há alguns valores nulos importantes, como a altura dos jogadores, o que ia me exigir um tratamento futuro.



Depois disso, eu fui analisar as Transferências e o Valor de Mercado. Eu fiz isso plotando alguns histogramas para entender a distribuição dos valores. Inicialmente eu fiz um plot na escala original, porém devido a forma como estavam os dados, tive que fazer na escala logarítmica, já que os preços variam de forma absurda (jogadores de custo zero e outros valendo centenas de milhões de euros).



Algo que eu achei interessante foi agrupar os valores de transferências por ano, o que permitiu visualizar claramente como a média de valor de mercado e das taxas de transferência evoluiu ao longo do tempo.

Além disso, eu criei um mapa de calor para cruzar a quantidade de registros por liga e ano, mas não achei tão útil.

Ao analisar as aparições, percebi algo que me chamou muita atenção. Eu filtrei as aparições do Lionel Messi em que ele marcou gols e o dataset retornou apenas 303 registros. Sinceramente, isso mostra que o dataset está incompleto, pois ele marcou gols em mais de 600 partidas, o que indica que não são todos os datasets do conjunto que cobriam dos anos 2000 até agora, esse por exemplo, começa em 2012 apenas, o que é menos tempo do que eu esperava. Isso é um ponto importante, ou seja, invés de confiar cegamente que eu tenho todos os dados do mundo do futebol, eu preciso estar ciente dessa limitação na hora de treinar e avaliar meus modelos.

2.2 Pré-processamento dos Dados

Depois eu foquei no pré-processamento dos dados para o primeiro modelo. O objetivo é transformar tudo que estava em texto ou quebrado em variáveis numéricas estruturadas, além de evitar qualquer tipo de data leakage, que foi uma das minhas dificuldades durante o projeto.

Primeiro, eu tratei as aparições dos jogadores. Eu achei mais útil agrupar as estatísticas por jogador e por temporada, invés de manter os dados granulares partida a partida. Isso resume o desempenho de forma que o modelo consiga entender a "fase" do jogador.

No dataset de Clubes, eu me deparei com a coluna `net_transfer_record` no formato de string monetária, então tive que criar uma função para converter isso tudo em números decimais reais. Além disso, eu criei uma classificação do nível da liga `league_tier` para indicar se o time está em uma liga de primeira divisão da Europa, segunda divisão, etc, afinal, a liga do jogador impacta diretamente no valor do de mercado, e para um modelo como o XGBoost que eu iria utilizar, fazer uma classificação ordinal é muito melhor do que um one hot encoder.

O critério que eu defini para o `league_tier` foi o seguinte: tier 1 para a Premier League inglesa e a MLS (devido ao volume financeiro), tier 2 para a La Liga espanhola, tier 3 para Bundesliga, Serie A e Ligue 1 (as outras três do top 5 europeu), tier 4 para o restante das primeiras divisões da UEFA mais as principais ligas das Américas (brasileira, argentina, mexicana e colombiana), tier 5 para as demais primeiras divisões de outras confederações e as segundas divisões europeias, e tier 6 para tudo que sobrar. Essa hierarquia foi feita de forma subjetiva com base no prestígio e no volume financeiro médio das ligas, mas ela reflete bem a realidade do mercado de transferências, onde um jogador da Premier League tende a valer significativamente mais do que um equivalente em uma liga de menor expressão.

No caso dos Jogadores, a primeira coisa que eu fiz foi remover colunas como `market_value_in_eur` e `highest_market_value_in_eur`, já que prever o valor é exatamente o objetivo final. Eu também preenchi a altura dos jogadores faltantes usando a mediana de altura para a respectiva posição no campo, visto que

jogadores de defesa por exemplo costumam ser mais altos que meio campistas etc. Criei os OHE para pé dominante e sub-posições, pois nesse quesito eu não acho que seja tão impactante para o valor do jogador ainda, e também converti o ranking da FIFA das seleções para um ranking invertido, dando mais peso para o top 1, dessa forma, jogadores que representam seleções mais "pesadas" teriam maior valor.

Por fim, no script de Build Dataset, eu juntei tudo isso em um único dataframe. Um ponto importante aqui foi garantir que as estatísticas de aparições usadas para prever o valor de mercado fossem as da temporada anterior à data da avaliação, para não usar informações do futuro. Eu criei a coluna alvo `log_market_value` aplicando o logaritmo no valor de mercado, pois como visto na análise, a distribuição é muito assimétrica.

2.3 Treinamento do Modelo (Model 1)

Para o treinamento do primeiro modelo, comecei estabelecendo um baseline simples para ter um ponto de comparação, usando apenas a mediana dos valores agrupados por posição e nível da liga.

Eu escolhi utilizar o XGBoost `XGBRegressor` porque ele lida muito bem com dados tabulares e tem suporte para uso de GPU (treinei algumas vezes no google colabs, até meu limite acabar). Antes de treinar, eu fiz a separação dos dados de treino, validação e teste. Um ponto muito importante aqui é que eu fiz uma divisão temporal (dados até 2021 para treino, 2022 a 2023 para validação e de 2024 em diante para teste).

Para encontrar os melhores hiperparâmetros, eu utilizei a biblioteca Optuna, que invés de testar combinações aleatoriamente, o Optuna aprende quais configurações funcionam melhor a cada tentativa. Para garantir que o modelo não tivesse overfitting, fiz a validação cruzada usando `TimeSeriesSplit` com 5 divisões, mantendo o respeito à linha do tempo dos dados a cada fold. Eu rodei 100 tentativas no Optuna e ele me devolveu um conjunto de parâmetros bem otimizado.

Por fim, eu treinei o modelo final com esses melhores parâmetros e comparei com o baseline. O modelo conseguiu uma melhoria significativa no MAPE (Erro Percentual Absoluto Médio) e um bom valor no R^2 (coeficiente de determinação), o que mostra que o modelo está realmente conseguindo capturar os padrões e prever os valores de forma muito mais inteligente do que a mediana. Sinceramente, fiquei bastante satisfeito com esse resultado e com a agilidade que a GPU proporcionou no processo. O modelo e as métricas foram todos salvos para o uso na predição final. Quanto ao MAPE, vale adicionar que eu não consegui alcançar os objetivos definidos por mim mesmo inicialmente, mesmo após vários treinamentos e uma análise nos dados, eu concluí que por conta da distribuição dos valores dos

jogadores, seria muito difícil conseguir um valor bom para o MAPE, mesmo com o modelo sendo bom.

2.4 Pré-processamento dos Dados (Model 2)

Nesta etapa, eu precisei criar um segundo dataset para usar no modelo 2. O modelo 2 invés de usar o valor do jogador do transfermarkt, utiliza o valor previsto do modelo 1 para prever a taxa de transferência, e por isso precisei criar um segundo dataset.

A primeira coisa que eu fiz foi carregar o dataset de transferências e cruzar com os dados dos clubes para definir comprador e vendedor. Depois, eu utilizei o `merge_asof` para buscar as estatísticas exatas do jogador no momento imediatamente anterior à transferência, garantindo zero vazamento de dados do futuro.

Com as características do jogador na época da venda, eu carreguei o modelo 1 e fiz com que ele previsse o valor de mercado do jogador naquela data exata. Essa previsão do modelo 1 virou uma feature no modelo 2.

Além disso, eu notei que alguns clubes têm o costume de pagar muito mais caro ou vender muito mais caro do que o valor de mercado padrão. Para capturar isso, criei métricas chamadas `buyer_ratio` e `seller_ratio`, que calculam a mediana histórica dos últimos 5 anos de quanto aquele clube (ou liga, em casos de clubes sem muita informação de transferências) costuma pagar a mais ou a menos em relação ao valor previsto pelo modelo 1.

Por fim, adicionei features sobre a transferência em si se foi na janela de inverno ou verão, idade exata no dia da transferência, se é a mesma confederação e criei a variável alvo `log_transfer_fee`.

2.5 Treinamento do Modelo (Model 2)

Aqui eu fiz o treinamento do modelo 2. Devido a dificuldade de prever o valor de uma transferência, invés de treinar o XGBoost com a função de perda tradicional que foca na média, eu mudei o objetivo para `quantileerror`, que é útil para prever intervalos invés de um valor exato. Na prática, foram treinados 3 modelos


- Um modelo para estimar 15%, que serve como o piso da negociação.
- Um modelo para estimar 50%, que é a mediana (o valor mais provável da venda).
- Um modelo para estimar 85%, que serve como o teto da negociação.

Antes de treinar esses três modelos, eu mantive a boa prática da divisão temporal (treino com dados antes de 2022 e teste com dados de 2022 em diante) e utilizei

novamente o Optuna com TimeSeriesSplit para otimizar os hiperparâmetros, dessa vez focando no erro da mediana.


2.6 Avaliação dos modelos

Com os modelos treinados, fiz a avaliação deles.




A primeira análise foi feita antes mesmo do modelo 2 ser treinado, foi quando eu estava tentando entender por que o modelo 1 não estava conseguindo atingir as métricas que eu tinha como meta no MAPE. Eu agrupei o dataset 1 por faixa de valor (ex: menos de 1 milhão, de 1 a 5 milhões, etc) e fiz uma previsão falsa, mas suficiente, utilizando o valor da avaliação passada do jogador como "previsão do próximo valor", e notei que o modelo erra muito mais nos jogadores muito baratos, pois qualquer diferença pequena em dinheiro representa uma porcentagem alta. Analisando o gráfico, seria necessário eliminar todos os jogadores com valor menor que 10 Milhões apenas para aumentar essa estatística do MAPE, apesar de que eu não imagino que isso vá realmente mudar no resultado do modelo em si, afinal o resultado do R^2 já estava suficiente, por isso, preferi deixar assim mesmo.

Modelo 1: Valor Previsto vs Valor Real




Modelo 2: Previsto vs Real (P50)




Após finalizar o treinamento dos dois modelos, a primeira coisa que eu fiz foi plotar um gráfico de dispersão scatter plot comparando o valor real da transferência com a


previsão mediana. Como usamos escala logarítmica, os dados se alinham bem em torno da linha de identidade, o que mostra que o modelo consegue capturar a tendência geral dos preços.



Algo que eu achei extremamente útil foi avaliar a cobertura do intervalo de confiança. Eu plotei alguns exemplos aleatórios onde a linha vertical representava o intervalo e o X vermelho representava o preço real pago. Na maioria das vezes, o preço real cai dentro do intervalo previsto.

Porém, eu fui investigar os outliers. então separei os casos em que o clube pagou mais que o dobro do nosso teto (P85) e os casos onde o jogador foi vendido por menos da metade do piso (P15). Analisando os nomes dos jogadores e os clubes envolvidos nesses casos, percebe-se que são negociações muito incomuns, tendo compras inflacionadas por clubes muito ricos ou vendas de jogadores que estavam com problemas internos com o clube.






Para entender a inteligência do modelo, eu fiz uma análise com o SHAP. Os gráficos de dependência mostraram claramente que a idade e o histórico de gastos do clube têm um impacto gigantesco na previsão do modelo 1, enquanto no modelo 2, o valor que teve mais impacto foi justamente o valor previsto pelo modelo 1.

2.7 Pipeline

Fluxo do Pipeline



Por fim, a última etapa do projeto foi fazer um script que utilizasse os 2 modelos para prever por quanto um jogador poderia ser vendido em uma negociação entre dois clubes.

O primeiro foi o `predict.py`, onde eu criei a classe `TransferPredictor`. Esse script carrega os modelos salvos, lida com as features necessárias e usa a biblioteca `rapidfuzz` para permitir buscas aproximadas pelos nomes dos jogadores e clubes. Depois, fiz uma cli utilizando a biblioteca `rich` para desenhar os menus e fazer uma interface básica. O fluxo de execução passa por escolher o jogador, o clube que tem a posse dele para vender e quem vai comprar, ou então simplesmente calcular o valor do jogador.

Testando com alguns jogadores, eu vi que para acertar o valor do jogador, o modelo está muito bom. Na vida real, vários outros fatores são levados em consideração, como por exemplo até o impacto de mídia que o jogador tem, mas no modelo não tem como isso ser avaliado, esse ponto, ao ser analisado por um lado, é ruim porque não consegue pegar o valor original do `transfermarkt`. Mas a plataforma não é a fonte da verdade, ela serve apenas como base, se olhado por outro ponto de vista, esse modelo pode ser considerado até melhor, pois foca apenas no desempenho do jogador, e não em fatores externos. "Futebolisticamente" falando, o valor proposto no modelo pode até ser mais útil que o do `transfermarkt`.

Quanto ao modelo 2, algumas previsões ficaram com valores realmente muito abaixo do valor do jogador previsto pelo próprio modelo, como uma previsão que eu fiz do Vinicius Junior sendo vendido do real madrid para o manchester city. Mas se

for analisar os fatos, o real madrid é um clube que não precisa de dinheiro, sempre que ele vende seus jogadores, são por conflitos, foi assim até com o Cristiano Ronaldo, Sergio Ramos e outros ídolos, o que acabou causando uma venda deles por valor muito abaixo. Se analisar por esse lado, até mesmo esse modelo 2 pode ter um bom resultado.

2.8 Intervalo de Cobertura

Uma das métricas que eu defini como meta para o modelo 2 foi que o intervalo P15–P85 cobrisse pelo menos 70% das transferências reais. O resultado final ficou em 53.9%, o que é bem abaixo. Eu tentei calibrar o modelo de diferentes formas durante o treinamento, mas não consegui chegar no número que eu queria.

A regressão quantílica aprende os quantis da distribuição que o modelo vê durante o treinamento. Se na fase de treino a maioria das transações se comporta de forma razoavelmente previsível, o modelo vai montar um intervalo adequado para esse grupo. Porém, o conjunto de teste (transferências de 2022 em diante) contém proporcionalmente mais negociações anômalas do que o treino, o que é reflexo de um mercado que ficou mais volátil no pós-pandemia. No conjunto de teste, eu identifiquei 218 casos em que o valor real pago foi mais do que o dobro do teto previsto pelo P85, e outros 104 em que o valor real ficou abaixo de metade do nosso piso P15. Esses 322 casos representam cerca de 6.6% das transações, mas sozinhos já explicam boa parte da cobertura perdida.

O ponto principal é que esses casos extremos não são previsíveis com os dados que temos. Quando o Paris Saint-Germain paga 222 milhões de euros pelo Neymar, ou quando um clube aciona uma cláusula de rescisão para contratar um jogador que não queria sair, essas decisões não são racionais do ponto de vista econômico. Nenhum feature observável no dataset (idade, estatísticas, nível da liga, confederation) consegue capturar essa informação. O modelo está correto para as transações onde existe alguma lógica de mercado, e simplesmente não tem como estar certo nas outras.

Para chegar próximo de 70% de cobertura, as alternativas seriam: ampliar o intervalo para P10–P90, o que aumentaria a cobertura mas tornaria o intervalo muito largo para ser útil na prática, ou então usar uma abordagem de conformal prediction para ajustar os limites empiricamente num conjunto de calibração separado. Eu tentei ampliar os quantis em uma versão experimental, mas o resultado foi um intervalo tão grande que perdeu o sentido como ferramenta de negociação. No final, preferi manter o P15–P85 e ser honesto sobre o que o modelo consegue e o que ele não consegue cobrir.

2.9 Metas não atingidas

Minha conclusão é que as metas que eu defini no início do projeto eram ambiciosas demais: MAPE abaixo de 30% para o modelo 1 e cobertura de intervalo acima de 70% para o modelo 2. Nenhuma das duas foi alcançada. O modelo 1 terminou com MAPE de 50.6% no conjunto de teste, e o modelo 2 com cobertura de 53.9%.

No caso do MAPE do modelo 1, o próprio indicador tem um comportamento problemático nesse domínio. Um jogador que vale 500 mil euros mas que o modelo previu como valendo 600 mil gera um erro percentual de 20%, enquanto um jogador que vale 50 milhões de euros com uma previsão de 45 milhões gera um erro de 10%, mesmo sendo um erro absoluto cem vezes maior. Como o dataset é cheio de jogadores baratos (a maior parte dos atletas profissionais vale menos de 1 milhão de euros), o MAPE fica inflado por esse grupo, mesmo que para os jogadores mais valiosos o modelo seja bastante preciso. O R^2 de 0.70 no conjunto de teste diz que o modelo explica 70% da variância dos valores, o que é um resultado bem sólido para um problema com tanta variabilidade. Então dependendo de qual métrica você olha, o modelo pode parecer ruim ou bom, e eu acho que o R^2 e o MAE absoluto contam a história mais honesta aqui.

O que me parece mais útil pensar é onde esse modelo entrega valor real e onde ele não entrega. Para o modelo 1, eu diria que ele funciona bem como uma âncora de valor justo baseada em desempenho. Um clube que quer saber se está pagando caro ou barato por um jogador pode usar o modelo como referência, com a ressalva de que fatores como marketing e nome do jogador no mercado não são capturados. Invés de substituir o valor do Transfermarkt, ele pode complementar, onde o Transfermarkt reflete percepção de mercado, esse modelo reflete o desempenho.

Já para o modelo 2, o intervalo P15–P85 é mais útil como um intervalo "justo". Se um clube recebe uma proposta por um jogador e o modelo indica que negociações similares ficam entre 8M e 20M de euros, isso ajuda a calibrar a negociação mesmo que o número final fuja do intervalo. Isso é especialmente útil para clubes menores, que podem não ter tanta informação de mercado quanto clubes maiores.

Em resumo, as metas que eu propus foram altas demais para o que os dados disponíveis permitem, e eu não percebi isso antes de iniciar o desenvolvimento do projeto. As limitações identificadas apontam claramente o que precisaria melhorar numa versão futura, tendo mais dados sobre negociações, informações sobre cláusulas de rescisão, e talvez variáveis de contexto externo como pressão de torcida ou interesse público no jogador.

3. Conclusão

Nesse projeto eu consegui colocar em prática todo o fluxo de desenvolvimento de um modelo de machine learning, passando pela análise dos dados, pré-processamento, otimização de hiperparâmetros e criação de um pipeline final. Foi muito interessante ver como o uso de dois modelos sequenciais, onde o primeiro alimenta o segundo, funciona na prática para resolver um problema mais complexo. Algo que eu achei extremamente útil foi a mudança da função de perda no modelo 2 para prever os quantis invés de focar na média. Isso me permitiu criar intervalos de confiança para as transferências, o que faz muito mais sentido no mundo do futebol, já que o preço de uma venda raramente é um número exato e depende muito do momento do mercado e do poder de compra dos times. Porém, eu enfrentei algumas dificuldades, principalmente em relação ao vazamento de dados temporais, e ao entender por que algumas estatísticas estavam indo bem enquanto o MAPE estava distante. Apesar do modelo não acertar tudo perfeitamente, já que fatores externos como mídia afetam muito na vida real, eu estou satisfeito com os resultados obtidos.

4. Referências

[Kaggle](#)

[Transfermarkt](#)

[XGBoost](#)

[Optuna](#)

[TimeSeriesSplit](#)

[MAPE](#)